



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ
НА ТЕМУ:
«Классификация методов распознавания летательной
техники с аэрофотоснимков»

Студент ИУ7-71Б
(Группа)

(Подпись, дата)

ИУ7-71Б
(И. О. Фамилия)

Руководитель ВКР

(Подпись, дата)

М. Д. Мицевич
(И. О. Фамилия)

Консультант

(Подпись, дата)

К. Л. Тассов
(И. О. Фамилия)

2023 г.

РЕФЕРАТ

Расчетно-пояснительная записка к курсовой работе содержит страниц, 0 иллюстраций, 1 таблиц, 12 источников, 1 приложение.

Научно-исследовательская работа представляет собой изучение предметной области классификации объектов на аэрофотоснимках, описание основных методов, а также преимуществ и недостатков каждого из них. Рассмотрены различные подходы решения поставленной задачи. Представлено описание алгоритмов детерминированного подхода, дерева решений и нейронных сетей. Подробно разобраны преимущества и недостатки перцептрона, сверточных нейронных сетей и капсульных нейронных сетей.

Ключевые слова: нейрон, перцептрон, сверточная нейронная сеть, капсульная нейронная сеть.

СОДЕРЖАНИЕ

| | |
|---|-----------|
| ВВЕДЕНИЕ | 5 |
| 1 Анализ предметной области | 6 |
| 1.1 Детерминированный подход | 6 |
| 1.2 Экспертный подход | 6 |
| 1.3 Нейрокомпьютерный подход | 8 |
| 1.3.1 Математическая модель МакКаллока-Питтса | 8 |
| 1.3.2 Функции активации | 9 |
| 1.3.3 Составляющие нейронной сети | 10 |
| 1.3.4 Методы оптимизации | 11 |
| 1.3.5 Функции потерь | 12 |
| 2 Анализ существующих решений | 13 |
| 2.1 Перцептрон | 13 |
| 2.2 Сверточные нейронные сети | 14 |
| 2.3 Капсульные нейронные сети | 15 |
| 2.4 Сравнение решений | 16 |
| ЗАКЛЮЧЕНИЕ | 18 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ | 20 |
| ПРИЛОЖЕНИЕ А Презентация | |

ВВЕДЕНИЕ

Одной из основных задач, возникающих при обработке изображений, является распознавание и классификация различных объектов на снимке. В роли объектов может быть различная техника: вертолеты, самолеты, машины, корабли.

Обработка в реальном времени полезна для задач контроля движения судов, поиска объектов на местности в случае аварии и крушения, предотвращение таких ситуаций, картографии.

Целью данной работы является анализ существующих методов распознавания и классификации объектов с фотоснимков.

Для достижения поставленной цели требуется выполнить следующие задачи:

- определить термины, связанные с предметной областью распознавания объектов;
- провести классификацию и разобрать методы распознавания с фотоснимков;
- определить недостатки и преимущества каждого из них.

1 Анализ предметной области

1.1 Детерминированный подход

Детерминированный подход основан на сравнении признаков распознаваемого объекта с признаками эталона и предполагает, что в любой точке пространства признаков могут появляться реализации только одного класса объектов. Алгоритмы данного подхода должны иметь возможности к автосмещению, автомасштабированию и автоповороту.

Одним из таких является алгоритм распознавания изображений на основе градиентного совмещения объекта с эталоном, предложенный в сборнике статей [1].

Все алгоритмы детерминированного подхода можно разбить на 4 основных шага:

1. выделение контуров объектов;
2. выбор наиболее информативных узловых точек эталона и объекта, а также установление связи между ними;
3. совмещение точек, на этом шаге должна осуществляться инвариантность к смещению, повороту и масштабированию;
4. принятие решения о принадлежности объекта к тому или иному классу.

Основным преимуществом такого подхода является то, что для классификации не требуется никаких данных, кроме эталонных изображений.

Главным недостатком является сложность получения устойчивого контура на зашумленных изображениях.

1.2 Экспертный подход

Методы данного подхода основаны на разделении всего множества входных объектов по некоторым заранее заданными критериям. Одним из таких методов является дерево решений.

Дерево решений представляет собой иерархическую древовидную структуру в узлах, которой содержатся условия. Условия генерируются при создании дерева, то есть в процессе обработки обучающего множества данных. Листьями дерева являются конкретные классы по которым производится классификация.

Процесс построения дерева решений предполагает рекуррентное последовательное разбиение обучающего множества на подмножества с применением решающих правил в узлах дерева. Процесс разбиения продолжается до тех пор, пока во всех листах не будет содержаться конкретных класс, по которому производится классификация. Узел становится листом либо когда он содержит объект одного класса, либо когда достигнуто какое-либо из условий останова, к примеру, достигнута максимальная глубина дерева.

При построении дерева используются жадные алгоритмы, которые выбирают оптимальные решения для конкретного шага алгоритма, а не всей системы целиком. То есть при выборе условия разбиения множества на два подмножества алгоритм будет выбирать лучшее только для этого шага и не сможет в дальнейшем вернуться и изменить его, даже если это будет оптимальнее для всей системы целиком.

На каждом этапе выбирается одно условие из всех возможных по средством максимизации функции прироста информации [2]. Для ее вычисления необходимо сначала задать функцию ошибки. К примеру, можно использовать среднюю квадратичную ошибку 1.1

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_{true} - y_{pred_i})^2, \quad (1.1)$$

где n – число элементов в подмножестве, y_{true} – значение атрибута в узле дерева, y_{pred_i} – значение атрибута в i элементе подмножества.

Тогда функция прироста информации может быть выражена зависимостью 1.2

$$IG = MSE_{root} - \left(\frac{n_{left}}{n} MSE_{left} - \frac{n_{right}}{n} MSE_{right} \right), \quad (1.2)$$

где MSE_{root} – значение ошибки в корневом узле, MSE_{left} – значение ошибки в левом подмножестве, MSE_{right} – в правом подмножестве.

Таким образом, на каждом шаге построения дерева из всех возможных условий выбирается то, для которого значение функции прироста информации

будет наибольшим. В узлах, в которых значение функции ошибки равно 0 или остался всего один элемент, процесс построения дерева останавливается и они считаются листьями.

1.3 Нейрокомпьютерный подход

Методы данного подхода основаны на создании и последующим обучении некоторой математической модели. Алгоритмы данного подхода можно разделить на две категории:

1. контролируемое обучение, в этом случае обучение алгоритмов контролируется разработчиком в процессе работы;
2. обучение без учителя, в этом случае обучение алгоритмов не предполагает участие разработчика, желаемые результаты неизвестны и определяются самим алгоритмом.

К алгоритмам первой категории можно относиться нейронные сети. Алгоритмы обучения без учителя не используются в задачах классификации.

Модель нейронной сети основана на биологическом нейроне. Почти все нейроны устроены примерно одинаково. У нейрона есть ядро, которое называется телом. В теле накапливается электрический заряд. С телом соединены отростки. Отростки, по которым сигнал поступает в тело, называются дендритами. Отросток, по которому сигнал передается другим нейронам, называется аксоном. Место, где аксон соединяется с дендритами, называется синапсом. Синапс отвечает за количество заряда, которое перейдет от аксона к дендриту. Синапс может изменяться со временем. Именно с настройкой синапса и связана тренировка биологической нейронной сети.

1.3.1 Математическая модель МакКаллока-Питтса

В математической модели МакКаллока-Питтса, тело нейрона, где накапливается заряд, заменяется на сумматор. Дендриты являются входами сумматора, а выходом – аксоном. Биологический нейрон накапливает заряд до

тех пор, пока этот заряд не достигнет какого-то значения, и только после этого этот заряд уходит по аксону к другим нейронам. В математической модели к сигналу после выхода из сумматора применяется функция активации и только после этого сигнал попадает на дендрит следующего нейрона. Синапсы в математической модели заменяются на веса входов нейрона. Математическая модель нейрона выражается зависимостью 1.3

$$y = f \left(\sum_{i=1}^n (w_i x_i) + b \right), \quad (1.3)$$

где y – сигнал на выходе из нейрона, f – функция активации, w_i – вес i входа, x_i – сигнал этого входа, b – некоторое значение смещения, которое задается отдельно для каждого нейрона. Обучение нейронной сети происходит за счет настройки синаптических весов w_i и смещения b .

1.3.2 Функции активации

Существует много различных функций активации (фактически любая функция может быть функцией активации). Наиболее популярными считаются логистическую функцию, гиперболический тангенс, ReLU [3]. Важной особенностью функций активации является их дифференцируемость (хотя для некоторых функций это выполняется не всегда), поскольку при обратном распространении ошибки необходимо вычислять градиенты, использующие производную функции активации.

Логистическая функция преобразовывает поступающие в неё значения в вещественный диапазон $[0, 1]$. Это означает, что при $x > 0$ выходное значение будет примерно равно единице, а при $x < 0$ будет близким к нулю. Данная функция часто используется в задачах классификации [3]. Логистическая функция определяется зависимостью 1.4.

$$y = \frac{1}{1 + e^{-x}}. \quad (1.4)$$

Гиперболический тангенс схож с логистической функцией, но в отличие от нее может принимать отрицательные значения. Гиперболический тангенс

определяется зависимостью 1.5.

$$y = \frac{e^{2x} - 1}{e^{2x} + 1}. \quad (1.5)$$

Функция ReLU возвращает 0, если принимает отрицательный аргумент, в случае же положительного аргумента, функция возвращает само число. ReLU решает проблему обнуления градиента для положительных чисел, также она вычисляется гораздо проще, чем сигмоидальные функции (логистическая функция, гиперболический тангенс) [3].

1.3.3 Составляющие нейронной сети

При обучении нейронной сети используются две подвыборки обучающего множества. Вся обучающая выборка состоит из какого-то количества объектов, для которых известны признаки, на которые должна обучиться нейронная сеть. Первая подвыборка называется тренировочной и используется для итеративного обучения нейронной сети. Вторая называется тестовой и используется для оценки того, насколько хорошо обучена нейронная сеть.

Нейронную сеть определяют следующие параметры:

- архитектура нейронной сети – отвечает за то, как нейроны связаны между собой;
- функция потерь – определяет насколько точно работает модель [4];
- метод оптимизации – определяет способ уменьшения функции потерь на каждой итерации обучения.

Нейроны делятся на три типа: входной, скрытый и выходной. В том случае, когда нейросеть состоит из большого количества нейронов, вводят термин слоя. Соответственно, есть входной слой, который получает информацию, некоторое количество скрытых, которые ее обрабатывают и выходной слой, который выводит результат [5]. Количество скрытых слоев и число нейронов в каждом из них задают архитектуру нейронной сети.

1.3.4 Методы оптимизации

Самый используемый метод оптимизации – градиентный спуск [6]. Градиентный спуск основан на пошаговом приближении функции к локальному минимуму. На каждой итерации алгоритма новые значения получаются по формуле 1.6

$$w_1 = w_0 - \alpha \Delta f(w_0), \quad (1.6)$$

где w_1 – вектор новых значений, которые подбираются алгоритмом, w_0 – значения параметров на текущем шаге, $\Delta f(w_0)$ – вектор градиентов функции потерь по каждому из параметров на текущем шаге, α – скорость обучения.

На каждой итерации градиентного спуска требуется считать градиент функции потерь, которая зависит от функций активации каждого из нейронов сети. В связи с этим к функциям потерь и активации применяются требования по дифференцируемости.

В связи с тем, что градиентный спуск находит только локальный минимум, не всегда полученный результат будет оптимальным. Результат работы алгоритма зависит от изначальных настроек параметров нейронной сети.

Выделяют три основных типа градиентного спуска [6]:

- мини-пакетный градиентный спуск – в этом случае обучающий набор данных разбивается на небольшие партии, которые используются для расчета ошибки модели и обновления коэффициентов модели;
- стохастический градиентный спуск – в этом случае градиент оптимизируемой функции считается на каждом шаге не как сумма градиентов от каждого элемента выборки, а как градиент от одного, случайно выбранного элемента;
- пакетный градиентный спуск – это разновидность алгоритма градиентного спуска, который вычисляет ошибку для каждого примера в наборе обучающих данных, но обновляет модель только после того, как все обучающие примеры были оценены.

1.3.5 Функции потерь

Согласно исследованиям [7] для задачи классификации изображений самой эффективной функцией потерь являются категориальная перекрестная энтропия, которая определяется выражением 1.8

$$CM_i = - \sum_{i=1}^N t_i \log p_i, \quad (1.7)$$

где N – число классов классификации, t_i – 0 или 1 в зависимости от того принадлежит ли изображение на входе нейронной сети классу, за который отвечает i нейрон выходного слоя, p_i – результат на выходе из нейрона.

В задачах классификации используют категориальную перекрестную энтропию в качестве функции потерь. В таких случаях на выходном слое нейронной сети создается столько нейронов, сколько возможных классов может иметь объект на входе. В качестве функции активации для каждого из таких нейронов используют софт макс. Софт макс определяется выражением 1.8

$$SM_i = \frac{e^{y_i}}{\sum_{i=1}^N e^{y_i}}, \quad (1.8)$$

где y_i – результат на выходе из нейрона, к которому применяется функция активации, N – число нейронов в выходном слое, y_j – результат на выходе из j нейрона выходного слоя.

Знаменатель в выражении 1.8 отвечает за нормировку. Таким образом, каждый из нейронов выходного слоя показывает вероятность принадлежности объекта на входе нейронной сети к некоторому классу, а сумма всех этих вероятностей будет равна 1.

2 Анализ существующих решений

Методы детерминированного подхода плохо подходят для задачи классификации изображений с аэрофотоснимков в силу того, что не устойчивы к шуму.

Дерево решений не применимо для поставленной задачи, так как на этапе построения дерева не известны критерии, по которым можно классифицировать входную информацию.

Среди подходов к построению нейронных сетей можно выделить следующие:

- перцептрон;
- сверточные нейронные сети;
- капсульные нейронные сети.

2.1 Перцептрон

Перцептрон – математическая модель восприятия информации головным мозгом. Перцептрон состоит из трёх типов элементов, а именно: поступающие от сенсоров сигналы передаются ассоциативным элементам, а затем реагирующим элементам [8].

Каждый из типов элементов относится к определенному слою в архитектуре нейронной сети. Так все сенсоры располагаются на входном слое, ассоциативные элементы находятся на одном или нескольких скрытых слоях, реагирующие элементы занимают выходной слой.

Увеличение числа скрытых слоев или числа нейронов на этом слое не всегда приводит к улучшению точности работы нейронной сети, поэтому данные параметры, как правило, подбираются экспериментальным путем. Число нейронов на выходном слое соответствует числу классов, по которым проводится классификация. На входном слое перцептрона число нейронов равно числу пикселей на изображении, которые подаются на вход нейронной сети.

Для нейронов скрытого слоя применяется функция активации Relu, а для нейронов выходного слоя – софт макс.

2.2 Сверточные нейронные сети

Свёрточная нейронная сеть — нейронная сеть, в которой присутствует слой свёртки [9]. Свертка из себя представляет некоторую маску, которая называется ядром. Маска накладывается на пиксели исходного изображения с некоторым шагом, далее значения в маске перемножаются со значениями, которые эта маска покрыла, и результаты перемножений суммируются. Полученная сумма добавляется в результирующую матрицу сверточного слоя. Для сохранения размеров исходного изображения к нему добавляются столбцы и ряды из нулей перед началом свертки.

В случае когда на вход сверточному слою поступает трехканальное изображение, ядро свертки будет не двумерным, а трехмерным. Оно будет состоять из трех матриц – по одной для каждого канала. После применения свертки поочередно к каждому из каналов результаты суммируются и записываются в результирующую матрицу.

На одном сверточном слое к входной матрице может применяться не одна свертка, а сразу несколько. В таком случае каждая свертка считается по отдельности и записывается в свою результирующую матрицу. Результатом работы такого слоя будет несколько каналов с матрицами. Число каналов равно числу фильтров.

Таким образом, сверточный слой определяется величинами:

- *padding* – число нулевых строк и столбцов, которые добавляются к исходному изображению;
- *strides* – шаг свертки по столбцам;
- *stridey* – шаг свертки по строкам;
- N – число каналов на входе;
- M – число каналов на выходе.

Помимо сверточных слоев в сверточной нейронной сети присутствуют слой субдискретизации и полносвязный слой. В слое субдискретизации также присутствует свертка, которая с некоторым шагом проходится по входной матрице только вместо перемножения элементов и последующего суммирования выполняется какая-либо другая операция, к примеру, выбор наибольшего элемента. С помощью слоя субдискретизации достигается устойчивость к небольшим сдвигам входного изображения, а также уменьшается размерность последующих слоёв. Полносвязный слой – обычный скрытый слой многослойного перцептрона, соединённый со всеми нейронами предыдущего слоя [9].

Одной из первых сверточных является LeNet.

2.3 Капсульные нейронные сети

В капсульных нейронных сетях присутствует капсульный слой. Капсула строится на основе искусственного нейрона, но вместо скалярной расширяет его до векторной формы, что позволяет сохранять больше информации об объекте. На выходе мы получаем вектор, способный сохранять состояние объекта, например его позу [10]. Длина вектора определяет вероятность обнаружения объекта, а его положение отвечает за состояние объекта.

Функция активации в этом случае имеет вид 2.1

$$v_j = \frac{\|s_j\|^2}{1 + \|s_j\|^2} \frac{s_j}{\|s_j\|}, \quad (2.1)$$

где v_j – выходной вектор капсулы j , s_j – входные данные. Правая часть этого уравнения делает входной вектор единичным, а левая выполняет масштабирование таким образом, чтобы чем длиннее был входной вектор, тем ближе длина выходного была к единице, и чем меньше длина входного, тем ближе длина выходного к нулю.

Для всех капсул, кроме первого слоя, вход s_j является взвешанной суммой по всем векторам предсказаний u_{ji} из капсул в нижележащем слое, которые получаются путем умножения выходного u_i капсулы из нижележащего слоя на весовую матрицу W_{ij} . Таким образом вход в капсулу s_j определяется

выражением 2.2

$$s_j = \sum_i c_{ij} u_{ji}, \quad (2.2)$$

где c_{ij} – коэффициент связи между капсулами i и j , который определяется выражением 2.3

$$c_{ij} = \frac{e^{b_{ij}}}{\sum_k b_{ik}}, \quad (2.3)$$

где b_{ij} – вероятность того, что капсула i связана с капсулой j . Эти вероятности итеративно обновляются путем измерения соответствия между текущим выходом v_j капсулы j и предсказанием u_{ji} капсулы i . Соответствие считается как скалярное произведение v_j на u_{ji} .

2.4 Сравнение решений

Согласно исследованиям [11] сверточные нейронные сети имеют большую точность распознавания по сравнению с перцептроном, а также большую устойчивость к шумам и скорость обучения за счет возможности распараллеливания алгоритма.

Так как ядро свёртки для каждой карты признаков одно, это позволяет нейронной сети научиться выделять признаки вне зависимости от их расположения во входном изображении, что не возможно в перцептронах.

Недостатком сверточных нейронных сетей является то, что отбрасывается потенциально полезная информация, теряются пространственные связи между объектами или их частями. Помимо этого, проблема заключается в неспособности сети определять положение объекта в пространстве, а также реагировать на его изменения (такие как поворот или смещение) [10].

Капсульные нейронные сети лучше реагируют на мелкие отличия по сравнению со сверточными сетями, так как свертка является загромождением, требуют меньшее количество данных для обучения и снижают ошибку распознавания в другом ракурсе [12].

Критерии сравнения описанных выше подходов к построению нейронных сетей и результаты сравнения представлены в таблице 2.1.

Таблица 2.1 – Сравнение видов нейронных сетей

| | Перцептрон | Сверточные сети | Капсульные сети |
|-------------------------------------|-------------------|----------------------------|----------------------------|
| Число связей | больше всего | среднее | меньше всего |
| Точность распознавания | меньше всего | средняя | выше всего |
| Устойчивость к шумам | устойчив | устойчивы | не устойчивы |
| Возможность к распараллеливанию | есть | есть | есть |
| Определение положения объекта | не возможно | возможно | возможно |

ЗАКЛЮЧЕНИЕ

Не существует оптимальной структуры нейронной сети для решения задачи классификации объектов с изображений. Каждый из рассмотренных типов имеет свои преимущества и недостатки, а конкретная архитектура определяется поставленной задачей и ее допущениями.

В данной научно-исследовательской работе были:

- определены термины, связанные с предметной областью распознавания объектов;
- проведена классификация и разобраны методы распознавания самолетов с фотоснимков;
- определить недостатки и преимущества каждого из них.

В рамках работы были выполнены все поставленные задачи. Цель работы была достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Самойлин Е.* АЛГОРИТМ РАСПОЗНАВАНИЯ ИЗОБРАЖЕНИЙ НА ОСНОВЕ ГРАДИЕНТНОГО СОВМЕЩЕНИЯ ОБЪЕКТА С ЭТАЛОНОМ. — Сборник трудов XXV Международной научно-технической конференции, 2019. — с. 150.
2. *Мифтахова А. А.* ПРИМЕНЕНИЕ МЕТОДА ДЕРЕВА РЕШЕНИЙ В ЗАДАЧАХ КЛАССИФИКАЦИИ И ПРОГНОЗИРОВАНИЯ. — Поволжский государственный университет телекоммуникаций и информатики, 2016. — с. 7.
3. *Бабушкина Н. Е.* ВЫБОР ФУНКЦИИ АКТИВАЦИИ НЕЙРОННОЙ СЕТИ В ЗАВИСИМОСТИ ОТ УСЛОВИЙ ЗАДАЧИ. — Донской государственный технический университет, 2022. — с. 4.
4. *Антонов Г. В.* ПРОСТАЯ НЕЙРОННАЯ СЕТЬ И ЕЕ ПРАКТИЧЕСКОЕ ПРИМЕНЕНИЕ. — ФГБОУ ВО Великолукская государственная сельскохозяйственная академия, 2021. — с. 11.
5. *Левченко К. М.* Нейронные сети. — Белорусский государственный университет информатики и радиоэлектроники, 2022. — с. 5.
6. *Барвинский Д. А.* Применение метода градиентного спуска в решении задач оптимизации. — Тенденции развития науки и образования, 2021.
7. *Апарнев А. Н.* Анализ функций потерь при обучении сверточных нейронных сетей с оптимизатором Adam для классификации изображений. — ВЕСТНИК МОСКОВСКОГО ЭНЕРГЕТИЧЕСКОГО ИНСТИТУТА. ВЕСТНИК МЭИ, 2020.
8. *Митина О.* ПЕРЦЕПТРОН В ЗАДАЧАХ БИНАРНОЙ КЛАССИФИКАЦИИ. — Национальная ассоциация ученых, 2021. — с. 6.
9. *Сикорский О. С.* Обзор свёрточных нейронных сетей для задачи классификации изображений. — Новые информационные технологии в автоматизированных системах, 2017. — с. 8.
10. *Алексеев И. П.* ПЕРСПЕКТИВЫ ПРИМЕНЕНИЯ КАПСУЛЬНЫХ НЕЙРОННЫХ СЕТЕЙ В РАСПОЗНАВАНИИ ОБЪЕКТОВ НА ИЗОБРАЖЕНИЯХ. — ТИНЧУРИНСКИЕ ЧТЕНИЯ - 2021 «ЭНЕРГЕТИКА И ЦИФРОВАЯ ТРАНСФОРМАЦИЯ», 2021. — с. 4.

11. *Паршин С. Е.* Исследование параметров алгоритмов распознавания лиц. — Сборник научных трудов Новосибирского государственного технического университета, 2019. — с. 6.
12. *Береснев Д. В.* КЛАССИФИКАЦИЯ ГАЛАКТИК С ПОМОЩЬЮ КАПСУЛЬНЫХ НЕЙРОННЫХ СЕТЕЙ. — БГУИР, 2019. — с. 4.

ПРИЛОЖЕНИЕ А
Презентация

**Классификация методов
распознавания летательных
аппаратов с
аэрофотоснимков**

Студент: М. Д. Мицевич ИУ7-71Б
Руководитель: К. Л. Тассов

Цель и задачи

Цель: анализ существующих методов распознавания и классификации объектов. Для достижения цели необходимо с фотоснимков:

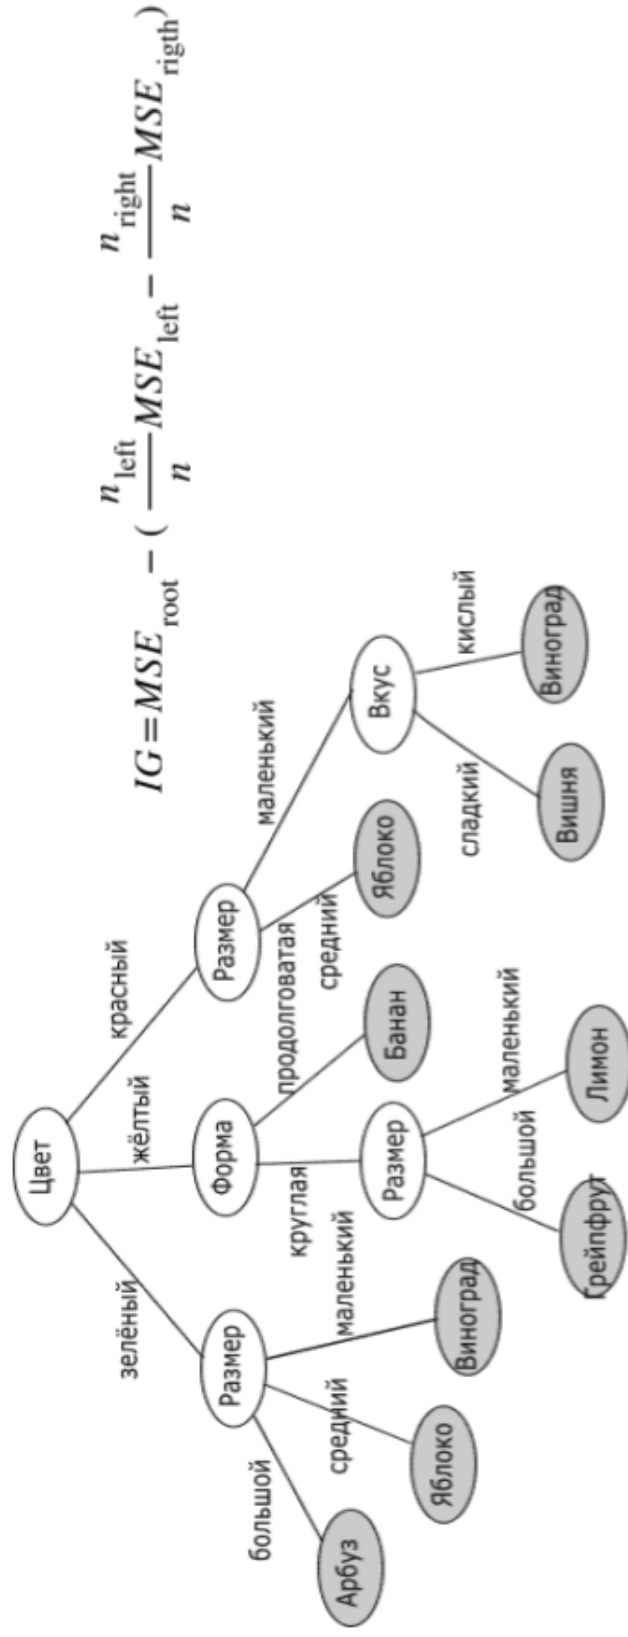
- определить термины, связанные с предметной областью;
- провести классификацию методов;
- определить недостатки и преимущества каждого из них.

Анализ предметной области


Выделяется три подхода:

- детерминированный – сравнение признаков распознаваемого с эталоном;
- экспертный – построение системы решений на основе критериев;
- нейрокомпьютерный – построение математической модели и обучение на основе специальной выборки.

Дерево решений




Модель МакКаллока-Питтса



Перцептрон

- S-элементы сенсоры
- A-элементы ассоциативные
- R-элементы реагирующие



Сверточные нейронные сети

- Сверточный слой
- Слой субдискретизации
- Полносвязный слой

Капсульные нейронные сети

- Реагирует на мелкие отличительные признаки
- Ниже ошибка распознавания в другом ракурсе
- Присутствуют пространственные связи